

**LAPORAN ANALISIS
MATA KULIAH
MACHINE LEARNING**

"Unsupervised Learning and Preprocessing"



Disusun Oleh :

Lovien Najla Dhafiyah (G1A024055)

Dosen Pengampu :

Ir. Arie Vatesia, S.T., M.T.I., Ph.D., IPP.

**PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNIK
UNIVERSITAS BENGKULU
2026**

BAB I

PENDAHULUAN

1.1 Latar Belakang

Machine learning (pembelajaran mesin) secara umum terbagi menjadi dua pendekatan besar, yaitu supervised learning (pembelajaran terawasi) dan unsupervised learning (pembelajaran tak terawasi). Pada supervised learning, model dilatih menggunakan data yang telah memiliki label atau target keluaran yang diketahui, sedangkan pada unsupervised learning model hanya diberikan data masukan tanpa label sama sekali, sehingga algoritma dituntut untuk menemukan pola atau struktur tersembunyi dari data tersebut secara mandiri.

Buku "Introduction to Machine Learning with Python" karya Andreas C. Müller dan Sarah Guido membahas topik ini secara mendalam pada Bab 3 dengan judul "Unsupervised Learning and Preprocessing". Bab ini menyajikan konsep beserta implementasi kode menggunakan pustaka scikit-learn pada bahasa pemrograman Python, mencakup tiga tema besar: (1) praproses dan penskalaan data (preprocessing and scaling), (2) reduksi dimensi dan ekstraksi fitur (dimensionality reduction and feature extraction), serta (3) pengelompokan data (clustering).

Laporan ini disusun untuk membahas dan menganalisis contoh-contoh kode yang terdapat pada Bab 3 tersebut, meliputi tujuan penggunaan setiap fungsi/algoritma, cara kerja singkatnya, serta hasil yang diperoleh dari eksekusi kode-kode tersebut.

1. 2 Rumusan Masalah

1. Bagaimana teknik praproses dan penskalaan data (scaling) diterapkan pada data numerik menggunakan scikit-learn?
2. Bagaimana algoritma reduksi dimensi seperti PCA, NMF, dan t-SNE bekerja dan diimplementasikan dalam kode Python?
3. Bagaimana algoritma clustering seperti k-Means, Agglomerative Clustering, dan DBSCAN diterapkan, serta bagaimana cara mengevaluasi hasil pengelompokan yang dihasilkan?

1.3 Tujuan

1. Memahami konsep dasar unsupervised learning beserta perbedaannya dengan supervised learning.
2. Menjelaskan langkah-langkah kode pada setiap contoh implementasi di Bab 3, mulai dari import pustaka, pembuatan objek model, hingga interpretasi hasil (output).
3. Menarik kesimpulan mengenai kelebihan, keterbatasan, serta kapan sebaiknya masing-masing metode digunakan.

BAB II

LANDASAN TEORI

2.1 Machine Learning

Machine Learning merupakan salah satu bagian dari kecerdasan buatan yang memungkinkan komputer mempelajari pola dari data untuk menghasilkan suatu prediksi atau menemukan struktur tertentu. Dalam proses pembelajaran mesin, model tidak hanya menjalankan aturan yang telah ditentukan secara manual, tetapi mempelajari hubungan atau pola yang terdapat pada data.

Pada praktikum ini, pembelajaran Machine Learning dibagi menjadi dua pendekatan utama, yaitu Supervised Learning dan Unsupervised Learning. Eksperimen dilakukan menggunakan Python dan Google Colab dengan memanfaatkan library scikit-learn. Pembahasan mengacu pada materi *Introduction to Machine Learning with Python*, khususnya bagian Supervised Learning serta Unsupervised Learning and Preprocessing.

Machine Learning tidak hanya berkaitan dengan menjalankan algoritma, tetapi juga dengan memahami karakteristik data, pemilihan model, parameter yang digunakan, serta bagaimana hasil model tersebut diinterpretasikan.

2.2 Supervised Learning

Supervised Learning merupakan pendekatan Machine Learning yang menggunakan data yang memiliki fitur dan target. Target berfungsi sebagai informasi mengenai jawaban yang benar sehingga model dapat mempelajari hubungan antara fitur dengan target tersebut.

Setelah model dilatih menggunakan data training, model diuji menggunakan data yang belum pernah dilihat sebelumnya. Hal ini berkaitan dengan konsep generalization, yaitu kemampuan model untuk bekerja dengan baik pada data baru.

Dalam Supervised Learning, terdapat kemungkinan terjadinya overfitting dan underfitting. Overfitting terjadi ketika model terlalu menyesuaikan diri dengan data training sehingga kurang mampu bekerja dengan baik pada data baru. Sebaliknya, underfitting terjadi ketika model terlalu sederhana sehingga belum mampu menangkap pola yang terdapat dalam data.

Beberapa algoritma Supervised Learning yang dibahas dalam praktikum ini adalah K-Nearest Neighbors, Linear Models, Naive Bayes, Decision Trees, Random Forest, Kernelized SVM, dan Neural Networks.

2.3 Unsupervised Learning

Berbeda dengan Supervised Learning, Unsupervised Learning tidak menggunakan target sebagai jawaban yang harus diprediksi. Model berusaha menemukan pola, struktur, atau hubungan yang terdapat di dalam data berdasarkan karakteristik data itu sendiri.

Dalam praktikum ini, Unsupervised Learning dibahas melalui dua tujuan utama, yaitu dimensionality reduction/representation dan clustering.

Dimensionality reduction atau representasi digunakan untuk mendapatkan bentuk data yang lebih sederhana sehingga pola atau struktur tertentu lebih mudah dianalisis. Algoritma yang digunakan dalam bagian ini adalah:

- a. PCA (Principal Component Analysis)
- b. NMF (Non-negative Matrix Factorization)
- c. t-SNE (t-distributed Stochastic Neighbor Embedding)

Sementara itu, clustering digunakan untuk mengelompokkan data berdasarkan karakteristik atau kedekatan tertentu. Algoritma yang digunakan adalah:

- a. k-Means
- b. Agglomerative Clustering
- c. DBSCAN


Karena Unsupervised Learning tidak memiliki target sebagai jawaban yang benar, proses analisis hasilnya juga berbeda dengan Supervised Learning. Hasil dapat dianalisis melalui struktur data, visualisasi, maupun metrik tertentu yang sesuai dengan metode yang digunakan.

BAB III

PEMBAHASAN

3.1 K-Nearest Neighbors (KNN)


K-Nearest Neighbors (KNN) merupakan salah satu algoritma *supervised learning* yang bekerja dengan menentukan kedekatan suatu data baru terhadap data yang telah diketahui kelasnya. Prediksi dilakukan berdasarkan kelas dari sejumlah tetangga terdekat (*nearest neighbors*). Buku menjelaskan bahwa semakin banyak tetangga yang digunakan, keputusan klasifikasi ditentukan berdasarkan kelas mayoritas dari tetangga tersebut.



Visualisasi tersebut memperlihatkan bagaimana KNN melakukan klasifikasi menggunakan satu tetangga terdekat. Data baru ditampilkan sebagai tanda bintang, kemudian algoritma mencari titik data pada dataset pelatihan yang memiliki jarak paling dekat. Kelas dari titik terdekat tersebut digunakan sebagai hasil prediksi. Buku juga memberikan contoh dengan tiga tetangga melalui Figure 2-5, sehingga dapat terlihat bahwa perubahan nilai k dapat mengubah hasil klasifikasi.

3.2 Linear Regression


Linear Regression merupakan algoritma *supervised learning* yang digunakan untuk melakukan prediksi terhadap nilai kontinu. Algoritma ini membangun hubungan linear antara variabel masukan dan variabel target. Dalam buku, Linear Regression dibahas pada bagian Linear Models yang dimulai pada halaman 45.



Linear Regression berusaha menemukan garis yang memberikan hubungan paling sesuai antara fitur masukan dan target. Hasil prediksi kemudian dapat dibandingkan dengan nilai aktual untuk melihat kemampuan model dalam melakukan generalisasi. Model ini sederhana dan mudah dipahami, tetapi performanya dapat terbatas ketika hubungan antara fitur dan target bersifat kompleks atau tidak linear.

3.3 Ridge Regression


Ridge Regression merupakan pengembangan dari Linear Regression yang menambahkan regularisasi untuk mengendalikan besarnya koefisien model. Regularisasi tersebut membantu mengurangi kompleksitas model dan dapat digunakan untuk mengatasi masalah *overfitting*.



Parameter alpha menentukan tingkat regularisasi yang diberikan kepada model. Nilai alpha yang lebih besar memberikan regularisasi yang lebih kuat sehingga koefisien model menjadi lebih kecil. Dengan demikian, Ridge Regression dapat menghasilkan model yang lebih terkendali dibandingkan Linear Regression ketika jumlah fitur relatif banyak atau terdapat risiko *overfitting*.

3.4 Naive Bayes



Naive Bayes merupakan algoritma klasifikasi yang menggunakan pendekatan probabilistik. Algoritma ini membuat asumsi bahwa fitur-fitur yang digunakan dalam proses klasifikasi bersifat independen satu sama lain berdasarkan kelas yang diamati.



Naive Bayes menghitung probabilitas suatu data termasuk ke dalam kelas tertentu berdasarkan fitur yang dimilikinya. Meskipun memiliki asumsi independensi fitur yang sederhana, algoritma ini dapat bekerja dengan baik pada beberapa jenis permasalahan klasifikasi. Proses pelatihan juga relatif cepat karena model terutama melakukan perhitungan statistik terhadap data pelatihan.

3.5 Decision Tree


Decision Tree merupakan algoritma klasifikasi maupun regresi yang membentuk struktur seperti pohon untuk mengambil keputusan. Setiap percabangan merepresentasikan kondisi terhadap suatu fitur, sedangkan bagian akhir pohon atau *leaf* menunjukkan hasil prediksi.



Decision Tree bekerja dengan melakukan pembagian data secara bertahap berdasarkan fitur tertentu. Pada setiap percabangan, data dipisahkan menjadi kelompok yang semakin homogen terhadap target. Salah satu kelebihan visualisasi Decision Tree adalah proses pengambilan keputusan dapat diamati secara langsung melalui struktur pohonnya.

3.6 Random Forest


Random Forest merupakan algoritma *ensemble* yang menggabungkan banyak Decision Tree. Setiap pohon dilatih menggunakan variasi data dan fitur sehingga keseluruhan model dapat menghasilkan prediksi yang lebih stabil dibandingkan hanya menggunakan satu pohon.



Random Forest menggunakan banyak pohon keputusan kemudian menggabungkan hasil prediksi dari pohon-pohon tersebut. Pada klasifikasi, hasil akhir ditentukan berdasarkan suara mayoritas. Pendekatan *ensemble* membuat model tidak hanya bergantung pada satu struktur pohon sehingga dapat memberikan model yang lebih robust terhadap variasi data.

3.7 Kernelized Support Vector Machine


Kernelized Support Vector Machine (SVM) merupakan algoritma klasifikasi yang dapat digunakan untuk menemukan batas pemisah antar kelas. Dengan menggunakan fungsi kernel, SVM dapat menangani hubungan yang tidak linear pada data.



Kernel memungkinkan SVM bekerja pada data yang tidak dapat dipisahkan secara linear pada ruang fitur awal. Kernel RBF, misalnya, memungkinkan model membentuk batas keputusan yang lebih kompleks. Karena SVM sensitif terhadap skala fitur, proses *scaling* juga menjadi bagian penting sebelum model dilatih.

3.8 Neural Network (MLP)


Neural Network atau Multi-Layer Perceptron (MLP) merupakan model yang tersusun atas beberapa lapisan neuron. Model ini dapat mempelajari hubungan yang kompleks melalui proses pembaruan bobot selama pelatihan.



MLP terdiri atas lapisan input, satu atau beberapa lapisan tersembunyi, dan lapisan output. Setiap neuron pada suatu lapisan terhubung dengan neuron pada lapisan berikutnya. Melalui proses pembelajaran, bobot hubungan tersebut diperbarui sehingga model dapat mempelajari pola pada data. Buku menempatkan MLP dalam pembahasan Neural Networks (Deep Learning).

3.9 Principal Component Analysis (PCA)


Principal Component Analysis (PCA) merupakan metode *unsupervised learning* yang digunakan untuk melakukan reduksi dimensi. PCA mencari arah atau komponen yang mampu menjelaskan variasi terbesar pada data. Algoritma ini dibahas dalam buku mulai halaman 140.



PCA mengubah data dari sejumlah fitur awal menjadi sejumlah komponen utama yang lebih sedikit. Komponen tersebut merupakan kombinasi linear dari fitur awal. Dengan menggunakan beberapa komponen utama, data dengan dimensi tinggi dapat direpresentasikan dalam dimensi yang lebih rendah sehingga lebih mudah divisualisasikan dan dianalisis.

3.10 Non-Negative Matrix Factorization (NMF)


Non-Negative Matrix Factorization (NMF) merupakan metode reduksi dimensi dan ekstraksi fitur yang membatasi komponen dan koefisiennya agar bernilai non-negatif. NMF dibahas dalam buku mulai halaman 156.



Pada visualisasi tersebut, NMF dan PCA digunakan untuk memperoleh representasi komponen dari data sinyal. Hasilnya menunjukkan bahwa NMF dapat menemukan pola sumber yang terdapat pada data campuran dengan karakteristik yang sesuai dengan batasan non-negatifnya. PCA memiliki tujuan yang berbeda karena mencari komponen berdasarkan variasi data, sehingga hasil komponennya tidak selalu merepresentasikan sumber asli secara langsung.

3.11 t-SNE

t-SNE (*t-distributed Stochastic Neighbor Embedding*) merupakan metode *manifold learning* yang terutama digunakan untuk visualisasi data berdimensi tinggi. Algoritma ini berusaha mempertahankan hubungan kedekatan antar data ketika data diproyeksikan ke ruang berdimensi lebih rendah.




t-SNE memetakan data berdimensi tinggi menjadi representasi dua dimensi dengan mempertahankan hubungan kedekatan antartitik. Data yang memiliki karakteristik serupa di ruang asli diharapkan berada berdekatan pada hasil visualisasi. Oleh karena itu, t-SNE banyak digunakan untuk eksplorasi dan visualisasi struktur data, bukan sebagai model klasifikasi utama.

3.12 k-Means Clustering

k-Means merupakan algoritma *unsupervised learning* yang digunakan untuk mengelompokkan data ke dalam sejumlah kelompok atau *cluster*. Jumlah cluster ditentukan terlebih dahulu melalui parameter k .

Cluster memberships:

```
[9 2 5 4 2 7 9 6 9 6 1 0 2 6 1 9 3 0 3 1 7 6 8 6 8 5 2 7 5 8 9 8 6 5 3 7 0
9 4 5 0 1 3 5 2 8 9 1 5 6 1 0 7 4 6 3 3 6 3 8 0 4 2 9 6 4 8 2 8 4 0 4 0 5
6 4 5 9 3 0 7 8 0 7 5 8 9 8 0 7 3 9 7 1 7 2 2 0 4 5 6 7 8 9 4 5 4 1 2 3 1
8 8 4 9 2 3 7 0 9 9 1 5 8 5 1 9 5 6 7 9 1 4 0 6 2 6 4 7 9 5 5 3 8 1 9 5 6
3 5 0 2 9 3 0 8 6 0 3 3 5 6 3 2 0 2 3 0 2 6 3 4 4 1 5 6 7 1 1 3 2 4 7 2 7
3 8 6 4 1 4 3 9 9 5 1 7 5 8 2]
```




k-

Means bekerja dengan menentukan pusat cluster atau *cluster center*, kemudian setiap data ditempatkan pada cluster dengan pusat terdekat. Proses tersebut dilakukan secara iteratif sampai posisi pusat cluster relatif stabil. Algoritma ini sesuai untuk data yang struktur clusternya dapat direpresentasikan menggunakan pusat cluster.

3.13 Agglomerative Clustering


Agglomerative Clustering merupakan metode *hierarchical clustering* yang membentuk struktur pengelompokan secara bertahap. Prosesnya dimulai dari setiap data sebagai kelompok tersendiri, kemudian kelompok-kelompok tersebut digabung berdasarkan kedekatannya.



Dendrogram memperlihatkan proses penggabungan kelompok secara hierarkis. Semakin tinggi posisi penggabungan pada dendrogram, semakin besar jarak antara kelompok yang digabungkan. Visualisasi tersebut dapat digunakan untuk memahami struktur hierarki dari kelompok-kelompok yang terbentuk.

3.14 DBSCAN

DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) merupakan algoritma clustering berbasis kepadatan. Berbeda dengan k-Means yang membutuhkan jumlah cluster sejak awal, DBSCAN menentukan cluster berdasarkan kepadatan data dan dapat mengidentifikasi data yang dianggap sebagai *noise*.



DBSCAN mengelompokkan data berdasarkan kepadatan titik di suatu wilayah. Data yang memiliki cukup banyak tetangga dalam radius tertentu dapat menjadi bagian dari suatu cluster, sedangkan titik yang tidak memenuhi kondisi kepadatan dapat dianggap sebagai *noise*. Pendekatan ini membuat DBSCAN dapat menemukan bentuk cluster yang tidak harus berbentuk lingkaran atau memiliki pusat tertentu.

BAB IV

PENUTUP

4.1 Kesimpulan

Berdasarkan pembahasan yang telah dilakukan, *machine learning* memiliki berbagai algoritma yang dapat digunakan sesuai dengan karakteristik dan tujuan pengolahan data. Pada *supervised learning*, algoritma K-Nearest Neighbors (KNN), Linear Regression, Ridge Regression, Naive Bayes, Decision Tree, Random Forest, Kernelized Support Vector Machine, dan Neural Network (MLP) digunakan untuk mempelajari pola berdasarkan data yang memiliki target atau label. Masing-masing algoritma memiliki pendekatan yang berbeda dalam melakukan klasifikasi maupun regresi.

Pada *unsupervised learning*, Principal Component Analysis (PCA), Non-Negative Matrix Factorization (NMF), t-SNE, k-Means, Agglomerative Clustering, dan DBSCAN digunakan untuk menemukan struktur, pola, representasi, atau kelompok pada data tanpa menggunakan label target. PCA dan NMF dapat digunakan untuk memperoleh representasi data yang lebih sederhana, t-SNE membantu visualisasi data berdimensi tinggi, sedangkan k-Means, Agglomerative Clustering, dan DBSCAN digunakan untuk melakukan pengelompokan berdasarkan karakteristik data.

Melalui pembahasan dan visualisasi yang terdapat dalam *Introduction to Machine Learning with Python*, dapat dipahami bahwa pemilihan algoritma perlu disesuaikan dengan jenis permasalahan, karakteristik data, serta tujuan analisis. Visualisasi hasil penerapan algoritma juga membantu dalam memahami proses kerja dan pola yang dihasilkan oleh masing-masing metode. Dengan memahami karakteristik berbagai algoritma tersebut, penerapan *machine learning* dapat dilakukan secara lebih terarah sesuai dengan kebutuhan permasalahan yang dihadapi.

DAFTAR PUSTAKA

- Müller, A. C., & Guido, S. (2017). *Introduction to machine learning with Python: A guide for data scientists*. O'Reilly Media.
- Müller, A. C. (n.d.). *Introduction to machine learning with Python: preprocessing and unsupervised learning notebook* [Jupyter Notebook].
GitHub.https://github.com/amueller/introduction_to_ml_with_python